


DataFlow-EDU

端到端学科语料库与Benchmark自动化生成管线



从原始教材PDF到高质量评测集的全生命周期方案 | 算子化 · 半自动化 · 低幻觉 · 多学科通用

学科大模型能力评测面临数据困境

现有数据集构建方式的三大瓶颈




图1. 人工标注成本指数级攀升示意




图2. 现有数据集质量分布与常见缺陷




图3. 题型与能力层级分布对比

DataFlow-EDU 的核心定位

通用、自动化、算子化的学科数据生产基础设施

输入：任意学科教材 PDF



输出：高质量评测集




Demo：高中生物必修一

均衡分布的低幻觉学科
评测集与训练语料



自动化



算子化




半自动人工监控

通用架构，支持任意学科输入


四阶段端到端管线架构

从文档解析到模型评测的完整算子链路



阶段一：Configuration Manager

双层知识体系与题型的灵活配置（类LlamaFactory风格）



考察形式

单选题

多选题


填空题

简答题

论述题

阶段一： MinerU OCR Operator

批量多模态PDF解析，输出标准化Markdown语料



阶段二：Generation Operator

两阶段LLM生成 + 随机槽机制精准控制分布

Stage 1

两页Markdown合并



LLM
知识方向分类器

大类：细胞结构 /
小类：细胞膜功能

Stage 2

大类：细胞结构 / 小类：细胞膜功能

随机槽 Slot 机制

	题型	单选	填空	简答
能力层级	记忆	●●●	●	●
	理解	●	●●●	●
	应用	●	●	●●●
	分析	●	●	●

LLM
题目生成器

题目+答案


题目1: ...
答案1: ...
题目2: ...
答案2: ...
题目3: ...
答案3: ...

随机槽机制确保分布精准均衡，题型写死不依赖LLM返回

阶段二：Balancing Operator


分布均衡诊断——从补题工具升级为知识覆盖顾问

题型分布分析



✓ 分布均衡（随机槽已保证）

知识方向覆盖分析



⚠ 遗传信息覆盖不足




建议：请补充「遗传信息」相关教材语料，以提升该方向题目覆盖度

系统提供建议，人工决策是否补充——不强制生成

阶段三：多维清洗算子流水线


从粗筛到精炼的分级质量管控



清洗率约 40% | 精炼率约 15% | 去重率约 8%

LLM-as-a-Judge 清洗机制

三级质量评分驱动的智能过滤与自动优化



二义性

二义性评分度

领域相关性

领域相关性

答案正确性


答案正确性

表述清晰度

表述清晰度

阶段四：Execute & Judge

将Benchmark真正运行起来——模型作答与智能评判




WebUI 管线监控看板

Vue 3 + Node.js 实现的半自动化人工监控界面

SECTION 1 —



SECTION 2 —




SECTION 3 —



先验项目经验支撑

四大学科语料库项目的实战经验积累



ROBOTheory-79k

79,000
条语料

题目生成

二义性清洗

机器人理论专业语料库 | 构建完整题目生成流程



CyberSecCorpus

1.6T
语料规模

大规模处理

专业语料

网络安全专业语料库 | 超大规模数据工程经验

DataFlow-EDU



EE-Bench

电子信息
学科数据集

多模态题型

学科评测

电子信息学科数据集 | 多模态题型设计与实现



CNLaw-Bench

LLM
as-a-Judge


评测基准

智能裁判

中国法律大模型评测基准 | 开创性LLM-as-a-Judge评测体系

深度融合 DataFlow 算子化哲学

基于OperatorABC与OPERATOR_REGISTRY的标准化算子设计



集成方式

```
# 将本地DataFlow加入路径
sys.path.insert(0, "DataFlow/")

from dataflow.core.operator import (
    OperatorABC,
    OPERATOR_REGISTRY
)
from dataflow.logger import get_logger
```


标准化集成，工程规范

From One to Infinity



DataFlow-EDU：赋能各类学科大模型能力跃升的数据基础设施

任意学科教材输入 · 算子化可扩展架构 · 多语言·多场景



端到端全生命周期管线